

Reporte técnico de red neuronal para clasificación de basura

Tipo de red neuronal

1. Identificación: Red Neuronal Convolutinal (CNN - Convolutional Neural Network).

2. Justificación: Se utiliza una CNN porque está especialmente diseñada para procesar y clasificar imágenes, detectando patrones visuales como bordes, texturas y formas. En el contexto del proyecto, las CNN son ideales para aprender características espaciales relevantes de las imágenes y diferenciar materiales como plástico, papel, vidrio o metal con alta precisión.

Características principales

1. Capas:

- Capa de entrada: Tamaño ($100 \times 100 \times 1$), equivalente a 10,000 neuronas.
- Capas ocultas: Tres capas convolucionales con 32, 64 y 128 filtros respectivamente; una capa densa con 100 neuronas.
- Capa de salida: 5 neuronas con activación *softmax*.

2. Funciones de activación: Se utiliza *ReLU* en capas intermedias por su eficiencia computacional y capacidad para evitar el gradiente desaparecido. La capa de salida usa *softmax* para convertir los valores en probabilidades de clasificación.

3. Características arquitectónicas: Se incluye una capa *Dropout* (0.3) para reducir el sobreajuste, además de *MaxPooling* para disminuir la dimensionalidad y mejorar la eficiencia. Las imágenes se normalizan entre 0 y 1 para estabilizar el entrenamiento.

Algoritmo de entrenamiento

1. Descripción: El modelo se entrena con el optimizador *Adam*, basado en el descenso de gradiente con momentos adaptativos, junto con retropropagación del error. La función de pérdida utilizada es *sparse_categorical_crossentropy*.

2. Justificación: Adam ajusta automáticamente la tasa de aprendizaje para cada parámetro, acelerando la convergencia y mejorando la estabilidad, especialmente útil en datasets visuales con gran variabilidad.

Medición del rendimiento

1. Métrica: Exactitud (*accuracy*).

2. Relevancia: La precisión es una métrica adecuada porque el objetivo principal es clasificar correctamente cada tipo de basura. Es intuitiva y efectiva en conjuntos de datos equilibrados.

Evaluación de la formación

1. Proceso: Durante el entrenamiento, el modelo se evalúa usando un conjunto de validación separado. Al finalizar, se utiliza `model.evaluate()` para medir la pérdida y precisión en validación.

2. Criterios de efectividad: La capacitación se considera efectiva si la precisión en validación es alta (por encima del 85%) y la pérdida de validación es estable o decreciente respecto al entrenamiento.

Técnicas de validación

1. Método: Se aplica validación simple (*hold-out*), separando un subconjunto de los datos para validación. Se sugiere el uso de validación cruzada *k-fold* en futuras versiones para mayor robustez.

2. Importancia: La validación permite detectar sobreajuste y evaluar la capacidad de generalización del modelo ante imágenes no vistas, garantizando confiabilidad en entornos reales.